

**LAPORAN CLUSTERING KOMENTAR TIKTOK MENGGUNAKAN
DBSCAN, AGGLOMERATIVE, K-MEANS, DAN FUZZY C-MEANS**

Diajukan untuk memenuhi tugas Mata Kuliah Pemrosesan Bahasa Alami

Diampu oleh Prof. Dr. MULJONO, S.Si, M.Kom



Oleh:

Pramudia Ramadhan

A11.2022.14274

PROGRAM STUDI TEKNIK INFORMATIKA

FAKULTAS ILMU KOMPUTER

UNIVERSITAS DIAN NUSWANTORO

2025

1. Dataset

Dataset yang digunakan dalam penelitian ini merupakan hasil web scraping komentar dari akun TikTok resmi MPL Indonesia (@mpl.id.official), yang difokuskan pada salah satu unggahan video pertandingan antara tim RRQ dan ONIC pada ajang MPL ID Season 15. Komentar yang terkumpul berjumlah 2.500 baris, disimpan dalam format CSV dengan dua kolom, yakni nomor urut dan teks komentar. Tujuan dari pemrosesan data ini adalah untuk mengetahui pola opini pengguna TikTok terhadap kekalahan tim RRQ, sekaligus mengelompokkan topik-topik komentar yang muncul secara alami berdasarkan isi teks.

2. Metode preprocessing dan vektorisasi

Sebelum dilakukan proses klasterisasi, komentar-komentar tersebut mengalami tahapan *preprocessing* yang cukup komprehensif. Langkah pertama dilakukan dengan membersihkan teks dari komentar kosong dan karakter tidak relevan. Selanjutnya, dilakukan penggantian kata-kata tidak baku atau *slang* menggunakan kamus bahasa informal yang disusun secara manual, seperti mengganti "gw" menjadi "saya", atau "wkwk" menjadi "haha". Setelah itu, dilakukan proses tokenisasi, penghapusan *stopwords* dalam bahasa Indonesia menggunakan NLTK, serta stemming menggunakan library Sastrawi. Hanya komentar yang terdiri dari dua kata atau lebih yang disertakan ke tahap selanjutnya untuk menjamin kualitas analisis.

Untuk proses *vectorization*, digunakan teknik Word2Vec dengan parameter `vector_size=64`, `window=5`, dan `min_count=2`, yang dilatih langsung dari token hasil preprocessing. Representasi akhir dari tiap komentar adalah hasil rata-rata dari vektor kata penyusunnya. Data ini kemudian digunakan sebagai input utama dalam algoritma clustering.

3. Penjelasan metode clustering yang digunakan

Terdapat empat algoritma clustering yang digunakan dalam eksperimen ini, yaitu DBSCAN, Agglomerative Clustering (Hierarchical), K-Means, dan Fuzzy C-Means (FCM). DBSCAN dipilih karena kemampuannya dalam menangani data berdimensi tinggi dan mengenali noise atau outlier tanpa perlu menentukan jumlah kluster di awal. Parameter ϵ dan min_samples ditentukan berdasarkan analisis k-distance graph. Sedangkan untuk Agglomerative, K-Means, dan FCM, dilakukan iterasi dari jumlah cluster 2 hingga 6 untuk mencari konfigurasi terbaik menggunakan metrik Silhouette Score. FCM dilakukan dengan terlebih dahulu melakukan penskalaan data menggunakan MinMaxScaler.

4. Hasil evaluasi dan visualisasi

Evaluasi performa clustering dilakukan menggunakan dua metrik internal yaitu Silhouette Score dan Davies-Bouldin Index. Berdasarkan hasil pengujian, algoritma DBSCAN memberikan skor terbaik dengan nilai Silhouette sebesar 0.88 dan nilai Davies-Bouldin sebesar 0.07, menunjukkan pemisahan cluster yang sangat baik dan kepadatan yang tinggi dalam cluster. Sebaliknya, metode Agglomerative dan KMeans hanya memperoleh Silhouette di kisaran 0.49–0.50, dan FCM memiliki performa terendah dengan skor Silhouette sekitar 0.44.

Visualisasi hasil clustering dilakukan menggunakan t-SNE dan PCA. Setiap metode divisualisasikan secara terpisah, dan hasil kluster terlihat lebih terpisah jelas pada DBSCAN. Selain itu, dilakukan juga visualisasi menggunakan WordCloud untuk masing-masing cluster. Kata-kata yang sering muncul seperti “ayam”, “mental”, “gg”, “runnerup”, dan “kalah” muncul dominan dalam beberapa cluster, menggambarkan emosi pengguna yang kecewa terhadap tim yang kalah.

5. Analisis cluster

Analisis terhadap isi masing-masing cluster menunjukkan bahwa pengguna TikTok cenderung menyampaikan opini dalam bentuk sindiran atau komentar

sarkastik. Misalnya, pada cluster DBSCAN yang ditandai sebagai noise (-1), banyak ditemukan kata “ayam” yang digunakan secara menghina untuk menyindir tim yang kalah. Cluster lainnya mengandung kata-kata seperti “mental”, “blunder”, dan “kalah”, yang mengindikasikan topik pembahasan tentang performa pemain. Hal ini menunjukkan bahwa clustering berhasil mengelompokkan komentar berdasarkan sentimen dan konteks isi, meskipun tidak secara eksplisit menggunakan pendekatan sentiment analysis.

6. Kesimpulan dan saran perbaikan

Dari seluruh metode yang digunakan, DBSCAN terbukti paling unggul dalam mengelompokkan komentar TikTok secara alami tanpa perlu menentukan jumlah cluster. Ia juga mampu menangani outlier atau komentar yang tidak cocok dimasukkan ke dalam klaster manapun. Sementara itu, metode seperti Agglomerative, KMeans, dan FCM masih menghasilkan klaster yang lebih kabur dan tumpang tindih. Namun, hasil dari WordCloud tetap memberikan informasi yang berharga untuk memahami isi dan tema utama dari tiap klaster.

Sebagai saran pengembangan ke depan, metode vektorisasi dapat ditingkatkan menggunakan embedding yang lebih kontekstual seperti BERT, atau menggabungkan Word2Vec dengan TF-IDF secara hati-hati agar dimensi tidak terlalu timpang. Selain itu, dapat dipertimbangkan untuk menerapkan pendekatan sentiment-aware clustering, atau membuat dashboard interaktif berbasis web agar hasil analisis bisa digunakan langsung oleh pihak non-teknis.

7. Link Youtube Video

<https://youtu.be/YHfb6I2IbDw?feature=shared>